

Regresión lineal simple (Cap2. Wooldridge)

Ejercicios en computadora

Juan Miguel Rodríguez

2025-06-12

Introducción a la **econometría** Un enfoque moderno

4a. edición

Jeffrey M. Wooldridge
Michigan State University

CAPÍTULO 2

El modelo de regresión simple

```
library(glue)
```

```
## Warning: package 'glue' was built under R version 4.4.3
```

```
library(wooldridge)
```

```
## Warning: package 'wooldridge' was built under R version 4.4.3
```

Ejercicio 2.1

C2.1 La base de datos 401K.RAW es un subconjunto de los datos analizados por Papke (1995) para estudiar la relación entre la participación en un plan de pensión y la generosidad del plan. La variable *prate* es el porcentaje de trabajadores que están inscritos en el plan y que tienen cuenta activa; ésta es la variable que se quiere explicar. La medida de la generosidad es la tasa de contribución (de la empresa) al plan, *mrte*. Esta variable es la cantidad promedio con la que la empresa contribuye al plan de cada trabajador por cada \$1 que aporte el trabajador. Por ejemplo, si $mrte = 0.50$, entonces a una contribución de \$1 del trabajador corresponde una contribución de 50 centavos de la empresa.

- i) Encuentre el promedio de la tasa de participación y el promedio de la tasa de contribución para la muestra.
- ii) Ahora, estime la ecuación de regresión simple

$$\widehat{prate} = \hat{\beta}_0 + \hat{\beta}_1 mrte,$$

y dé los resultados, el tamaño de la muestra y *R*-cuadrada.

- iii) Interprete el intercepto de la ecuación. Interprete también el coeficiente de *mrte*.
- iv) Determine la *prate* que se predice para $= 3.5$. ¿Es razonable esta predicción? Explique qué ocurre aquí.

Cargamos y nombramos los datos *k401k* obtenidos del paquete “wooldridge”:

```
data("k401k", package = "wooldridge")
df1 <- k401k
```

I. Promedio de las tasas de participación y contribución para la muestra

Con la función *mean* calculamos los promedios de las variables *prate* y *mrte* del dataframe *df1*:

```
participación_media = round(mean(df1$prate), 3)
contribución_media = round(mean(df1$mrte), 3)
```

```
glue("La tasa media de participación es: {participación_media}")
```

```
## La tasa media de participación es: 87.363
```

```
glue("La tasa media de contribución es: {contribución_media}")
```

```
## La tasa media de contribución es: 0.732
```

II. Estimación de la ecuación de regresión simple

Con la función `lm(linearmodel)` estimamos la ecuación de la tasa de participación en función de la tasa de contribución:

$$\widehat{\text{prate}} = \beta_0 + \beta_1 \cdot \text{mrate}$$

```
modelo_1 <- lm(prate ~ mrate, data = df1)
summary(modelo_1)
```

```
##
## Call:
## lm(formula = prate ~ mrate, data = df1)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -82.303  -8.184   5.178  12.712  16.807
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  83.0755     0.5633  147.48  <2e-16 ***
## mrate         5.8611     0.5270   11.12  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 16.09 on 1532 degrees of freedom
## Multiple R-squared:  0.0747, Adjusted R-squared:  0.0741
## F-statistic: 123.7 on 1 and 1532 DF,  p-value: < 2.2e-16
```

De los resultados de la regresión se entiende que el coeficiente β_1 es significativo al 0.01% y que el R^2 es del 0.075.

III. Interpretación del intercepto y del coeficiente de contribución

$$\widehat{\text{prate}} = 83.0755 + 5.8611 \cdot \text{mrate}$$

- El intercepto $\beta_0 = 83.07$ indica que si la empresa no aporta ningún dólar, se espera que la tasa de participación en el plan sea de 83.07%.
- El coeficiente de *mrate*, $\beta_1 = 5.86$, indica que por cada dólar adicional que aporte la empresa por cada dólar aportado por el profesional, se espera que la tasa de participación en el plan aumente en promedio 5.86 puntos porcentuales.

IV. Tasa de participación estimada para una tasa de contribución de 3.5

$$\widehat{\text{prate}} = 83.0755 + 5.8611 \cdot 3.5$$

```
beta_0 = 83.075
beta_1 = 5.86
mrate = 3.5

estimado = 83.0755 + 5.86 * 3.5
estimado
```

```
## [1] 103.5855
```

Esta predicción no es razonable, pues estima que para una contribución de 3.5 dólares por dólar, la tasa de participación será del 103.58%, cuando se entiende que la tasa máxima de participación es del 100%.

Ejercicio 2.2

C2.2 La base de datos CEOSAL2.RAW contiene información sobre directores generales de empresas (CEO) estadounidenses. La variable *salary* es el sueldo anual, en miles de dólares, y *ceoten* son los años de antigüedad como CEO de la empresa.

- Determine el sueldo y la antigüedad promedio en esta muestra.
- ¿Cuántos de estos directivos se encuentran en su primer año como CEO (es decir, *ceoten* = 0)? ¿Cuál es la mayor antigüedad entre estos CEO?
- Estime el modelo de regresión simple

$$\log(\text{salary}) = \beta_0 + \beta_1 \text{ceoten} + u,$$

y dé los resultados en la forma usual. ¿Cuál es el aumento porcentual (aproximado) que se pronostica en el sueldo por cada año adicional de antigüedad como CEO?

Cargamos y nombramos los datos *ceosal2* obtenidos del paquete “wooldridge”:

```
data("ceosal2", package = "wooldridge")
df2 <- ceosal2
```

I. Sueldo y antigüedad media de la muestra

Con la función *mean* calculamos los promedios de las variables *salary* y *ceoten*:

```
salario_medio = round(mean(df2$salary), 3)
tenure_medio = round(mean(df2$ceoten), 3)
```

```
glue("El salario medio es: {salario_medio}")
```

```
## El salario medio es: 865.864
```

```
glue("La antigüedad media es: {tenure_media}")
```

```
## La antigüedad media es: 7.955
```

II. Número de CEO's que están en su primer año ($ceoten = 0$) y antigüedad máxima

Con la función *sum* contamos las filas (CEO's) para las cuales la variable *ceoten* es igual a cero:

```
sum(ceosal2$ceoten == 0)
```

```
## [1] 5
```

Con la función *max* obtenemos el valor máximo que toma la variable *ceoten*:

```
max(ceosal2$ceoten)
```

```
## [1] 37
```

III. Estimación del modelo de regresión simple Log-Nivel

$$\widehat{\log(\text{salary})} = \beta_0 + \beta_1 \cdot \text{ceoten}$$

Aplicamos logaritmo natural a la variable *salary*:

```
df2$ln_salary = log(df2$salary)
```

Calculamos el modelo con *lm*:

```
modelo_2 = lm(ln_salary ~ ceoten, data = df2)
summary(modelo_2)
```

```
##
## Call:
## lm(formula = ln_salary ~ ceoten, data = df2)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.15314 -0.38319 -0.02251  0.44439  1.94337
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  6.505498   0.067991  95.682  <2e-16 ***
## ceoten       0.009724   0.006364   1.528   0.128
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.6038 on 175 degrees of freedom
## Multiple R-squared:  0.01316,    Adjusted R-squared:  0.007523
## F-statistic: 2.334 on 1 and 175 DF,  p-value: 0.1284
```

Modelo estimado:

$$\log(\text{salary}) = 6.505 + 0.009724 \cdot \text{ceotenure}$$

El coeficiente estimado de *ceoten* en el modelo log-nivel es 0.0097, lo que indica que por cada año adicional como CEO, el salario aumenta en promedio un 0.97%. Sin embargo, este efecto no es estadísticamente significativo, lo cual sugiere que no hay evidencia suficiente para afirmar que la antigüedad como CEO afecta el salario. Además, el R^2 del modelo es muy bajo (1.3%), lo que indica una capacidad explicativa limitada de este modelo.

Ejercicio 2.3

C2.3 Utilice los datos de SLEEP75.RAW de Biddle y Hamermesh (1990) para analizar si existe una relación inversa entre las horas de sueño por semana y las horas de trabajo pagado por semana. Cualquiera de las variables puede usarse como la variable dependiente. Estime el modelo

$$\text{sleep} = \beta_0 + \beta_1 \text{totwrk} + u,$$

donde *sleep* corresponde a minutos de sueño por semana durante la noche y *totwrk* corresponde al total de minutos de trabajo por semana.

- Dé sus resultados en forma de ecuación, además de la cantidad de observaciones y la R^2 . ¿Qué significa el intercepto de la ecuación?
- Si *totwrk* aumenta 2 horas, ¿cuánto se estima que disminuirá *sleep*? ¿Le parece que este efecto sea grande?

Cargamos y nombramos los datos *sleep75* obtenidos del paquete “wooldridge”:

```
data("sleep75", package = "wooldridge")
df3 <- sleep75
```

I. Estimación del modelo Nivel-Nivel

$$\text{sleep} = \beta_0 + \beta_1 \cdot \text{totwrk} + \mu$$

Calculamos el modelo con *lm*:

```
modelo_3 <- lm(sleep ~ totwrk, data = df3)
summary(modelo_3)
```

```
##
## Call:
## lm(formula = sleep ~ totwrk, data = df3)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2429.94  -240.25    4.91   250.53  1339.72
##
```

```
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 3586.37695   38.91243  92.165  <2e-16 ***
## totwrk      -0.15075    0.01674  -9.005  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 421.1 on 704 degrees of freedom
## Multiple R-squared:  0.1033, Adjusted R-squared:  0.102
## F-statistic: 81.09 on 1 and 704 DF,  p-value: < 2.2e-16
```

La ecuación estimada a partir de la regresión es:

$$\widehat{\text{sleep}} = 3586 - 0.15 \cdot \text{totwrk}$$

- La variable *totwork* es estadísticamente significativa al 1%; el R^2 es 0.1033, indicando que la variación en el total de horas de trabajo explica el 10.33% de la variación en las horas de sueño.
- Estos resultados sugieren que por cada minuto adicional de trabajo semanal, en promedio se reducen 0.15 minutos de sueño semanal.
- Además, el intercepto $\beta_0 = 3586$, significa que una persona desempleada, pensionada o que no trabaja, duerme en promedio 3586 minutos por semana durante la noche.

II. ¿Qué pasa con las horas de sueño cuando se trabajan dos horas semanales más?

Se crean los valores para evaluar el modelo y realizar la diferencia:

```
Beta_0 = 3586
Beta_1 = 0.15
totwrk = 120

estimado = Beta_0 - Beta_1 * totwrk
estimado
```

```
## [1] 3568
```

```
diferencia = Beta_0 - estimado
diferencia
```

```
## [1] 18
```

Si una persona trabaja 2 horas más a la semana, se estima que dormirá 18 minutos menos por semana, es decir, alrededor de 2.6 minutos menos por noche.

En términos relativos, perder 2.6 minutos por noche no parece ser un gran sacrificio por dos horas más de trabajo semanal.

Este cálculo también se puede realizar multiplicando el parámetro β_1 ($= 0.15$) por 120, es decir, los minutos adicionales:

```
Beta_1 * 120
```

```
## [1] 18
```

Ejercicio 2.4

C2.4 Use la base de datos WAGE2.RAW para estimar una regresión simple que explique el salario mensual (*wage*) en términos de la puntuación del coeficiente intelectual (*IQ*).

- Determine el promedio muestral del salario y de *IQ*. ¿Cuál es la desviación estándar muestral de *IQ*? (La puntuación del coeficiente intelectual está estandarizada, de manera que el promedio de la población es 100 y la desviación estándar es 15.)
- Estime un modelo de regresión simple en el que un aumento de un punto en *IQ* modifique *wage* en una cantidad de dólares constante. Use este modelo para determinar el aumento que se predice en *wage* para un aumento de 15 puntos en *IQ*. ¿Explica *IQ* la mayor parte de la variación en *wage*?
- Ahora, estime un modelo en el que cada aumento de un punto en *IQ* tenga un mismo efecto porcentual sobre *wage*. Si *IQ* aumenta 15 puntos, ¿cuál es el aumento porcentual pronosticado para *wage*?

Cargamos y nombramos los datos *wage2* obtenidos del paquete “wooldridge”:

```
data("wage2", package = "wooldridge")
df4 <- wage2
```

I. Promedio y desviación estándar muestral del salario e *IQ*

Con la función *mean* y *sd* podemos calcular el promedio y la desviación estándar de las variables:

```
salario_promedio = round(mean(df4$wage), 2)
salario_sd = round(sd(df4$wage), 2)
```

```
IQ_medio = round(mean(df4$IQ), 2)
IQ_sd = round(sd(df4$IQ), 2)
```

```
glue("El promedio del salario mensual e IQ son: {salario_promedio} y {IQ_medio}, respectivamente")
```

```
## El promedio del salario mensual e IQ son: 957.95 y 101.28, respectivamente
```

```
glue("La desviación estándar del salario mensual e IQ son: {salario_sd} y {IQ_sd}, respectivamente")
```

```
## La desviación estándar del salario mensual e IQ son: 404.36 y 15.05, respectivamente
```


II. Estimación de un modelo Nivel-Nivel

$$\text{wage} = \beta_0 + \beta_1 \cdot \text{IQ} + \mu$$

Calculamos el modelo con *lm*:

```
modelo_4_1 = lm(wage ~ IQ, data = df4)
summary(modelo_4_1)

##
## Call:
## lm(formula = wage ~ IQ, data = df4)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -898.7  -256.5   -47.3   201.1  2072.6
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  116.9916    85.6415   1.366   0.172
## IQ           8.3031     0.8364   9.927 <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 384.8 on 933 degrees of freedom
## Multiple R-squared:  0.09554,    Adjusted R-squared:  0.09457
## F-statistic: 98.55 on 1 and 933 DF,  p-value: < 2.2e-16
```

A pesar de que la variable *IQ* es estadísticamente significativa al 5%, el R^2 es de tan solo 0.095. Esto implica que la variación en IQ explica aproximadamente el 9.5% de la variación en el salario.

$$\widehat{\text{wage}} = 116.99 + 8.3 \cdot \text{IQ}$$

Calculamos el aumento salarial mensual que se predice para un aumento en 15 puntos del IQ.

Para este caso, asumimos un incremento de 100 IQ a 115 IQ. Sin embargo, cualesquiera sean los valores de IQ, el resultado será el mismo.

```
Beta_0 = 116.99
Beta_1 = 8.303

IQ_i = 100
IQ_f = 115

wage_100 = Beta_0 + Beta_1 * IQ_i
wage_115 = Beta_0 + Beta_1 * IQ_f

aumento_salarial = wage_115 - wage_100
aumento_salarial
```

```
## [1] 124.545
```

```
glue("El aumento salarial estimado para una diferencia de 15 puntos de IQ es de: {aumento_salarial}")
```

```
## El aumento salarial estimado para una diferencia de 15 puntos de IQ es de: 124.545
```

Este cálculo también se puede realizar multiplicando el parámetro β_1 ($= 8.303$) por 15, es decir, los puntos de IQ adicionales:

```
Beta_1 * 15
```

```
## [1] 124.545
```

III. Estimación de un modelo Log - Nivel

$$\log(\text{wage}) = \beta_0 + \beta_1 \cdot \text{IQ} + \mu$$

Para estimar este modelo, primero sacamos logaritmo natural a la variable *wage* con la función *log*:

```
df4$ln_wage = log(df4$wage)
```

Ahora, procedemos a estimar el modelo con la función *lm*:

```
modelo_4_2 = lm(ln_wage ~ IQ, data = df4)
summary(modelo_4_2)
```

```
##
## Call:
## lm(formula = ln_wage ~ IQ, data = df4)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2.09324 -0.25547  0.02261  0.27544  1.21486
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.8869943   0.0890206   66.13  <2e-16 ***
## IQ           0.0088072   0.0008694   10.13  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.3999 on 933 degrees of freedom
## Multiple R-squared:  0.09909,    Adjusted R-squared:  0.09813
## F-statistic: 102.6 on 1 and 933 DF,  p-value: < 2.2e-16
```

El modelo resultante es:

$$\widehat{\log(\text{wage})} = 5.886 + 0.0088 \cdot \text{IQ}$$

De este modelo se interpreta que por cada aumento de un punto en *IQ*, el incremento promedio en el salario es de 0.88%.

Ahora, si *IQ* incrementase 15 puntos (ejemplo, de 100 a 115), se debería realizar el siguiente procedimiento para estimar el incremento salarial:

```

Beta_0 = 5.886
Beta_1 = 0.0088
IQ_i = 100
IQ_f = 115

ln_wage_i = Beta_0 + Beta_1 * IQ_i
ln_wage_f = Beta_0 + Beta_1 * IQ_f

incremento_salarial = ln_wage_f - ln_wage_i
incremento_salarial

```

```
## [1] 0.132
```

Dado que estamos calculando la diferencia de dos logaritmos, este resultado se debe interpretar como un porcentaje. Luego, el incremento salarial promedio esperado es de: 13.2%

También se puede estimar multiplicando el coeficiente β_1 por 15, la diferencia en IQ, e interpretando el resultado como porcentaje:

```

Delta_IQ = 15
Delta_wage = Beta_1 * Delta_IQ

Delta_wage_porcentaje = Delta_wage * 100

glue("En este caso, se esperaría un incremento salarial promedio de: {Delta_wage_porcentaje}%")

```

```
## En este caso, se esperaría un incremento salarial promedio de: 13.2%
```

Ejercicio 2.5

C2.5 En la población formada por las empresas de la industria química, sea *rd* gastos anuales en investigación y desarrollo y *sales* ventas anuales (ambos en millones de dólares).

- Dé un modelo (no una ecuación estimada) que implique una elasticidad constante entre *rd* y *sales*. ¿Qué parámetro es la elasticidad?
- Ahora, estime el modelo usando la base de datos RDCHEM.RAW. Escriba la ecuación estimada en su forma usual. ¿Cuál es la elasticidad estimada para *rd* respecto a *sales*? Explique qué significa esta elasticidad.

Cargamos y nombramos los datos *rdchem* obtenidos del paquete “wooldridge”:

```

data("rdchem", package = "wooldridge")
df5 <- rdchem

```

I. Modelo para una elasticidad constante: Log - Log

Para estimar un modelo de elasticidad constante se debe aplicar logaritmo natural tanto a la variable dependiente, como a la independiente:

$$\log(\text{rd}) = \beta_0 + \beta_1 \cdot \log(\text{sales}) + \mu$$

En este modelo, el parámetro β_1 mide la elasticidad entre *rd* y *sales*.

II. Ecuación estimada para una elasticidad constante: Log - Log

Aplicamos logaritmo natural a ambas variables:

```
df5$ln_rd = log(df5$rd)
df5$ln_sales = log(df5$sales)
```

Estimamos el modelo con los logaritmos de estas variables:

```
modelo_5 = lm(ln_rd ~ ln_sales, data = df5)
summary(modelo_5)

##
## Call:
## lm(formula = ln_rd ~ ln_sales, data = df5)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.90406 -0.40086 -0.02178  0.40562  1.10438
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -4.10472    0.45277  -9.066 4.27e-10 ***
## ln_sales       1.07573    0.06183  17.399 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5294 on 30 degrees of freedom
## Multiple R-squared:  0.9098, Adjusted R-squared:  0.9068
## F-statistic: 302.7 on 1 and 30 DF,  p-value: < 2.2e-16
```

- Este modelo presenta un R^2 bastante alto, aproximadamente 0.91. Esto se interpreta en la medida en que la variación de las ventas (logaritmo de las ventas) explica aproximadamente el 91% de la variación en los gastos de investigación (logaritmo de los gastos de investigación).
- Además, la variable de ventas es estadísticamente significativa al 0.1%.

El modelo resultante se presenta como:

$$\widehat{\log(\text{rd})} = -4.104 + 1.0757 \cdot \log(\text{sales})$$

Esto significa que un aumento del 1% en las ventas se asocia, en promedio, con un aumento del 1.08% en el gasto en I+D.

Ejercicio 2.6

C2.6 En el ejemplo 2.12 se usan los datos de MEAP93.RAW. Ahora se quiere explorar la relación entre la tasa de aprobados en matemáticas (*math10*) y el gasto por estudiante (*expend*).

- i) ¿Piensa que cada dólar más que se gasta tiene un mismo efecto en la tasa de aprobados o parece más apropiado que haya un efecto decreciente? Explique.
- ii) En el modelo poblacional

$$\text{math10} = \beta_0 + \beta_1 \log(\text{expend}) + u,$$

justifique que $\beta_1/10$ es el cambio en puntos porcentuales en *math10* dado un aumento de 10% en *expend*.

- iii) Use los datos de MEAP93.RAW para estimar el modelo del inciso ii). Dé la ecuación estimada de la manera usual, incluyendo el tamaño de la muestra y *R*-cuadrada.
- iv) ¿Qué tan grande es el efecto estimado del gasto? Es decir, si el gasto aumenta 10%, ¿cuál es el aumento de *math10* en puntos porcentuales?
- v) Puede ser preocupante que el análisis de regresión produzca valores ajustados para *math10* que sean mayores a 100. ¿Por qué esto no es de preocupar en esta base estándar de datos?

Cargamos y nombramos los datos *meap93* obtenidos del paquete “wooldridge”:

```
data("meap93", package = "wooldridge")
df6 <- meap93
```

I. ¿Rendimientos crecientes o decrecientes?

Pienso que cada dólar extra invertido tiene menos efecto que el dólar anterior. Esto porque podría ser una inversión con rendimientos decrecientes: al principio, aumentos en el gasto pueden tener un efecto notable, pero luego ese efecto se reduce.

II. Demostración

Partiendo de:

$$\text{math10} = \beta_0 + \beta_1 \cdot \log(\text{expend}) + \mu$$

donde $\text{math10} \in (0, 100)$ representa el porcentaje de alumnos aprobados, se tiene un aumento del 10% en *expend*, tal que:

$$\text{expend}' = 1.1 \cdot \text{expend}$$

Luego, el cambio en *math10* se representa como:

$$\Delta \text{math10} = [\beta_0 + \beta_1 \cdot \log(1.1 \cdot \text{expend})] - [\beta_0 + \beta_1 \cdot \log(\text{expend})]$$

Operando, se tiene que:

$$\Delta \text{math10} = \beta_1 \cdot [\log(1.1 \cdot \text{expend}) - \log(\text{expend})]$$

Por propiedades de logaritmos, se tiene que:

$$\Delta \text{math10} = \beta_1 \cdot \log(1.1)$$

Calculando el logaritmo, se tiene que:

$$\Delta \text{math10} = \beta_1 \cdot 0.0953 \approx \beta_1 \cdot 0.1$$

III. Estimación del modelo Nivel - Log

Para estimar el modelo:

$$\widehat{\text{math10}} = \beta_0 + \beta_1 \cdot \log(\text{expend})$$

Primero debemos sacar logaritmo a la variable *expend*

```
df6$ln_expend = log(df6$expend)
```

Ahora, estimamos la regresión con *lm*:

```
modelo_6 = lm(math10 ~ ln_expend, data = df6)
summary(modelo_6)
```

```
##
## Call:
## lm(formula = math10 ~ ln_expend, data = df6)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -22.343  -7.100  -0.914   6.148  39.093
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  -69.341     26.530  -2.614  0.009290 **
## ln_expend     11.164       3.169   3.523  0.000475 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 10.35 on 406 degrees of freedom
## Multiple R-squared:  0.02966,    Adjusted R-squared:  0.02727
## F-statistic: 12.41 on 1 and 406 DF,  p-value: 0.0004752
```

De los resultados se destaca que la variable *ln_expend* es estadísticamente significativa al 0.1%. Sin embargo, el R^2 es de 0.03, lo que quiere decir que la variación en *ln_expend* explica tan solo el 3% de la variación en *math10*.

El parámetro estimado $\beta_1 = 11.164$, estima que por cada incremento de un 1% en el gasto por estudiante, se predice un incremento promedio de 0.11 puntos porcentuales en la tasa de aprobación de matemáticas. Esto dado que las unidades de *math10* están en puntos porcentuales.

La ecuación estimada se presenta como:

$$\widehat{\text{math10}} = -69.341 + 11.164 \cdot \log(\text{expend})$$

IV. Variación estimada en math10 a partir de un incremento de 10% en expend

Se sabe que en una regresión Nivel-Log, el parámetro β_1 se interpreta tal que:

$$\Delta y = \left(\frac{\beta_1}{100} \right) \% \Delta x$$

Remplazando en la ecuación anterior:

$$\Delta \text{math10} = \left(\frac{11.164}{100} \right) \% \cdot 10$$

Esto es:

```
beta_1 = 11.164
delta_expend = 10

delta_math = (beta_1 / 100) * 10
delta_math
```

```
## [1] 1.1164
```

$$\Delta \text{math10} = \left(\frac{11.164}{100} \right) \% \cdot 10 = 1.1164$$

Luego, de este resultado se entiende que para un incremento del 10% en expend, se espera un incremento promedio de 1.11 puntos porcentuales en math10.

V. ¿Math10 > 100?

Matemáticamente podría parecer preocupante que el modelo prediga valores mayores a 100, ya que math10 representa porcentaje de aprobados, y su valor teórico debería estar en el intervalo $\in (0, 100)$. Sin embargo, los modelos de regresión lineal no imponen restricciones sobre el rango de valores predichos. Además, en el dataset MEAP93, los valores reales de math10 están muy por debajo de 100.

Ejercicio 2.7

C2.7 Use la base de datos CHARITY.RAW [obtenidos de Franses y Paap (2001)] para responder a las preguntas siguientes:

- ¿Cuál es el donativo (*gift*) promedio en esta muestra de 4,268 personas (en florines holandeses)? ¿Qué porcentaje de estas personas no dio ningún donativo?
- ¿Cuál es el promedio de envíos por año (*mailsyear*)? ¿Cuáles son los valores mínimo y máximo?
- Estime el modelo

$$gift = \beta_0 + \beta_1 mailsyear + u$$

mediante MCO y dé los resultados de la manera usual, incluidos el tamaño de la muestra y la *R*-cuadrada.

- Interprete el coeficiente de la pendiente. Si cada envío cuesta un florín, ¿espera la beneficencia obtener una ganancia neta por cada envío? ¿Significa esto que la beneficencia obtiene una ganancia neta en cada envío? Explique.
- En esta muestra, ¿cuál es el menor donativo? Usando el análisis de regresión simple, ¿se puede predecir que *gift* sea igual a cero?

Cargamos y nombramos los datos *meap93* obtenidos del paquete “wooldridge”:

```
data("charity", package = "wooldridge")
df7 <- charity
```

I. Donativo “gift” promedio y porcentaje de personas que no donaron

Con la función *mean* calculamos el promedio de la variable *gift*. Luego, con *sum* y *nrow* calculamos el porcentaje de personas cuyo *gift* es igual 0.

```
mean(df7$gift)
```

```
## [1] 7.44447
```

```
sum(df7$gift == 0) / nrow(df7)
```

```
## [1] 0.6000469
```

II. Estadísticas descriptivas de “mailsyear”

```
summary(df7$mailsyear)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##      0.25   1.75   2.00   2.05   2.50   3.50
```


III. Estimación del modelo Nivel-Nivel

Estimaremos el siguiente modelo Nivel-Nivel con *lm*:

$$\text{gift} = \beta_0 + \beta_1 \cdot \text{mailsyear} + \mu$$

```
modelo_7 = lm(gift ~ mailsyear, data = df7)
summary(modelo_7)

##
## Call:
## lm(formula = gift ~ mailsyear, data = df7)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -11.287   -7.976   -5.976    2.687   245.999
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   2.0141     0.7395   2.724  0.00648 **
## mailsyear     2.6495     0.3431   7.723  1.4e-14 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 14.96 on 4266 degrees of freedom
## Multiple R-squared:  0.01379,    Adjusted R-squared:  0.01356
## F-statistic: 59.65 on 1 and 4266 DF,  p-value: 1.404e-14
```

La variable mailsyear es estadísticamente significativa al 0.1%. Sin embargo, el R^2 de la regresión es de 0.013, lo que significa que la variación en mailsyear explica tan solo el 1.4% de la variación en gift.

Luego, la ecuación estimada es la siguiente:

$$\widehat{\text{gift}} = 2.015 + 2.65 \cdot \text{mailsyear}$$

IV. Interpretación de la regresión

El coeficiente estimado de mailsyear fue 2.65, lo cual indica que por cada envío adicional de correo por año, el donativo promedio por persona aumenta en 2.65 florines.

Si cada envío cuesta 1 florín, entonces la ganancia neta esperada por cada envío es:

$$2.65 - 1 = 1.65 \text{ florines por envío}$$

Esto sugiere que la organización benéfica sí obtiene una ganancia neta esperada positiva por cada envío. Sin embargo, esta es una interpretación promedio. No todas las personas generan ingresos positivos; algunas no donan nada. Además, el modelo tiene un bajo poder explicativo ($R^2 \approx 0.014$), lo cual indica que muchos otros factores afectan los donativos.

V. Donativo mínimo e igual a cero

Con la función *min* calculamos el mínimo de la variable *gift*:

```
min(df7$gift)
```

```
## [1] 0
```

Usando el análisis de la regresión estimada, sí se puede predecir un valor de 0 para *gift*. Primero, se parte de la ecuación estimada:

$$\widehat{\text{gift}} = 2.015 + 2.65 \cdot \text{mailsyear}$$

Luego, igualamos $\widehat{\text{gift}}$ a 0:

$$\widehat{\text{gift}} = 0$$

Remplazamos en la ecuación estimada:

$$0 = 2.015 + 2.65 \cdot \text{mailsyear}$$

Despejamos *mailsyear*:

$$\begin{aligned} -\frac{2.015}{2.65} &= \text{mailsyear} \\ \text{mailsyear} &\approx -0.76 \end{aligned}$$

Sin embargo, vemos que nunca se predice un valor de $\text{gift} = 0$ dentro del rango válido de *mailsyear*, ya que para eso sería necesario un número negativo de envíos, lo cual no es posible.

Anexos

Anexo 1: Resumen de las formas funcionales en las que se emplean logaritmos

Modelo	Variable dependiente	Variable independiente	Interpretación de β_1
Nivel-nivel	y	x	$\Delta y = \beta_1 \Delta x$
Nivel-log	y	$\log(x)$	$\Delta y = \left(\frac{\beta_1}{100}\right) \% \Delta x$
Log-nivel	$\log(y)$	x	$\% \Delta y = (100\beta_1) \Delta x$
Log-log	$\log(y)$	$\log(x)$	$\% \Delta y = \beta_1 \% \Delta x$

Anexo 2: Supuestos de Gauss–Markov para la regresión lineal simple

A continuación se resumen los supuestos de Gauss–Markov empleados para la regresión lineal simple. Para demostrar que los estimadores $\hat{\beta}_0$ y $\hat{\beta}_1$ son insesgados, solo se requieren los supuestos RLS.1 a RLS.4. El supuesto RLS.5 (homocedasticidad) es necesario para obtener las fórmulas usuales de las varianzas de MCO.

Supuesto RLS.1: Lineal en los parámetros

En el modelo poblacional, la variable dependiente y está relacionada con la variable independiente x y un término de error u , de forma lineal:

$$y = \beta_0 + \beta_1 x + u$$

donde β_0 y β_1 son los parámetros poblacionales del intercepto y la pendiente, respectivamente.

Supuesto RLS.2: Muestreo aleatorio

Se tiene una muestra aleatoria de tamaño n :

$$\{(x_i, y_i) : i = 1, 2, \dots, n\}$$

que sigue el modelo poblacional descrito en el supuesto RLS.1.

Supuesto RLS.3: Variación en la variable explicativa

Los valores muestrales de x , es decir:

$$\{x_i : i = 1, 2, \dots, n\}$$

no son todos iguales. Esto garantiza que x tenga varianza positiva.

Supuesto RLS.4: Media condicional cero

Dado cualquier valor de la variable explicativa x , el valor esperado del término de error es cero:

$$\mathbb{E}(u \mid x) = 0$$

Esto implica que no hay correlación sistemática entre x y el error.

Supuesto RLS.5: Homocedasticidad

Para cualquier valor de la variable explicativa x , el término de error tiene varianza constante:

$$\text{Var}(u \mid x) = \sigma^2$$

Este supuesto es necesario para obtener las fórmulas estándar de los errores estándar y varianzas de los estimadores.

Anexo 3: Cálculo de $\hat{\beta}_1$ y R^2

Estimador de $\hat{\beta}_1$

El estimador de Mínimos Cuadrados Ordinarios para la pendiente de la regresión lineal simple es:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

Estimador de $\hat{\beta}_0$

Dado $\hat{\beta}_1$, el intercepto estimado es:

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Cálculo de R^2 a partir de las sumas de cuadrados

Se definen:

- **STC**: Suma Total de Cuadrados

$$\text{STC} \equiv \sum_{i=1}^n (y_i - \bar{y})^2$$

- **SEC**: Suma Explicada de Cuadrados

$$\text{SEC} \equiv \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

- **SRC**: Suma Residual de Cuadrados (también conocida como suma de residuos cuadrados)

$$\text{SRC} \equiv \sum_{i=1}^n \hat{u}_i^2$$

Estas tres cantidades cumplen la siguiente relación fundamental:

$$\text{STC} = \text{SEC} + \text{SRC}$$

A partir de esto, el coeficiente de determinación se define como:

$$R^2 \equiv \frac{\text{SEC}}{\text{STC}} = 1 - \frac{\text{SRC}}{\text{STC}}$$